

EGT 2010 : analyse des distributions

Cantien Collinet

Mercredi 17 juin 2020

Contents

1	Préparation des données	1
2	Exploration	3
2.1	Quartiles	3
2.2	Fonctions de densité	6
2.3	Statistiques descriptives	9
2.4	Courbes de Lorenz	11
2.5	Forme des distributions	14

1 Préparation des données

Installation des librairies et importation des données

```
source("support/preparation.R")

## Durée des déplacements ----

# Calcul des temps de déplacement
temps_brut <- déplacements %>%
  group_by(NQUEST, NP) %>%
  summarise(temps = sum(DUREE)) %>%
  left_join(individus_CS8_short, by = c("NQUEST", "NP")) %>%
  mutate(temps = tidyr::replace_na(temps, 0)) %>% # 0 pour les immobiles
  filter(!is.na(CS8)) %>%
  var_labels(temps = "Durée quotidienne de déplacement par personne (en min)")

# Tableau avec les individus de toutes les PCS de niveau 1
temps <- temps_brut %>%
  mutate(CS8 = sjlabelled::as_label(CS8, prefix = TRUE))
temps <- sjlabelled::copy_labels(temps, temps_brut)

# Données pondérées
temps_w <- svydesign(ids = ~1,
  data = temps,
  weights = ~POIDSP)

# Tableau avec uniquement les CPIS, employés et ouvriers
temps_subset <- subset(temps_brut, CS8 %in% c(3, 5, 6))
temps_subset <- temps_subset %>%
  mutate(CS8 = sjlabelled::as_label(CS8, prefix = TRUE))
```

```

temps_subset <- sjlabelled::copy_labels(temps_subset, temps_brut)

# Données pondérées
temps_subset_w <- svydesign(ids = ~1,
  data = temps_subset,
  weights = ~POIDSP)

## Distances parcourues ----

# Calcul des distances parcourues
distance_brut <- deplacements %>%
  group_by(NQUEST, NP) %>%
  summarise(distance = sum(DPORTEE)) %>%
  right_join(individus_CS8_short, by = c("NQUEST", "NP")) %>%
  mutate(distance = tidyr::replace_na(distance, 0)) %>% # 0 pour les immobiles
  filter(!is.na(CS8)) %>%
  var_labels(distance = "Distance parcourue quotidiennement par personne (en km)")

# Tableau avec les individus de toutes les PCS de niveau 1
distance <- distance_brut %>%
  mutate(CS8 = sjlabelled::as_label(CS8, prefix = TRUE))
distance <- sjlabelled::copy_labels(distance, distance_brut)

# Données pondérées
distance_w <- svydesign(ids = ~1,
  data = distance,
  weights = ~POIDSP)

# Tableau avec uniquement les CPIS, employés et ouvriers
distance_subset <- subset(distance_brut, CS8 %in% c(3, 5, 6))
distance_subset <- distance_subset %>%
  mutate(CS8 = sjlabelled::as_label(CS8, prefix = TRUE))
distance_subset <- sjlabelled::copy_labels(distance_subset, distance_brut)

# Données pondérées
distance_subset_w <- svydesign(ids = ~1,
  data = distance_subset,
  weights = ~POIDSP)

## Nombre de déplacements ----

# Calcul du nombre de déplacements
nb_deplacements_brut <- deplacements %>%
  group_by(NQUEST, NP) %>%
  count %>%
  right_join(individus_CS8_short, by = c("NQUEST", "NP")) %>%
  mutate(n = tidyr::replace_na(n, 0)) %>% # Individus immobiles
  filter(!is.na(CS8)) %>%
  var_labels(n = "Nombre de déplacements quotidiens par personne")

# Tableau avec les individus de toutes les PCS de niveau 1
nb_deplacements <- nb_deplacements_brut %>%
  mutate(CS8 = sjlabelled::as_label(CS8, prefix = TRUE))

```

```

nb_deplacements <- sjlabelled::copy_labels(nb_deplacements, nb_deplacements_brut)

# Données pondérées
nb_deplacements_w <- svydesign(ids = ~1,
                             data = nb_deplacements,
                             weights = ~POIDSP)

# Tableau avec uniquement les CPIS, employés et ouvriers
nb_deplacements_subset <- subset(nb_deplacements_brut, CS8 %in% c(3, 5, 6))
nb_deplacements_subset <- nb_deplacements_subset %>%
  mutate(CS8 = sjlabelled::as_label(CS8, prefix = TRUE))
nb_deplacements_subset <- sjlabelled::copy_labels(
  nb_deplacements_subset,
  nb_deplacements_brut
)

# Données pondérées
nb_deplacements_subset_w <- svydesign(ids = ~1,
                                    data = nb_deplacements_subset,
                                    weights = ~POIDSP)

```

2 Exploration

2.1 Quartiles


2.1.1 Durée des déplacements

```

ggplot(temps_w$variables, aes(
  weight = weights(temps_w),
  x = CS8,
  y = temps / 60,
  color = CS8)
) +
geom_boxplot(outlier.shape = NA, varwidth = TRUE) +
ggtitle(
  "Distribution de la durée quotidienne des déplacements par personne",
  subtitle = "(La largeur des boîtes à moustaches est proportionnelle au nombre d'individus)"
) +
ylab("Durée quotid. des déplacements (heures)") +
xlab("PCS de niveau 1") +
guides(color = FALSE) +
theme(axis.title.y = element_text(vjust = 0)) +
coord_cartesian(ylim = c(0, 5))


```

Distribution de la durée quotidienne des déplacements par personne
(La largeur des boîtes à moustaches est proportionnelle au nombre d'individus)




2.1.2 Distances parcourues

```
ggplot(distance_w$variables, aes(
  weight = weights(distance_w),
  x = CS8,
  y = distance,
  color = CS8)
) +
geom_boxplot(outlier.shape = NA, varwidth = TRUE) +
ggtitle("Distribution des distances quotidiennes parcourues par personne") +
ylab("Distance parcourue quotidiennement (km)") +
xlab("PCS de niveau 1") +
guides(color = FALSE) +
theme(axis.title.y = element_text(vjust = 0)) +
coord_cartesian(ylim = c(0, 100))
```



2.1.3 Nombre de déplacements

```
ggplot(nb_deplacements_w$variables, aes(
  weight = weights(nb_deplacements_w),
  x = CS8,
  y = n,
  color = CS8)
) +
geom_boxplot(outlier.shape = NA, varwidth = TRUE) +
ggtitle("Nombre de déplacements quotidiens par personne") +
ylab("Nombre de déplacements quotidiens") +
xlab("PCS de niveau 1") +
guides(color = FALSE) +
theme(axis.title.y = element_text(vjust = 0)) +
coord_cartesian(ylim = c(0, 12.5))
```




2.2 Fonctions de densité

Vérification qu'il n'y ait pas de valeurs fausses ou surprenantes dans la distribution.


2.2.1 Durée des déplacements

```
ggplot(temps_w$variables, aes(weight = weights(temps_w), x = temps)) +  
  geom_density()
```




2.2.2 Distances parcourues

```
ggplot(distance_w$variables, aes(weight = weights(distance_w), x = distance)) +  
  geom_density()
```



2.2.3 Nombre de déplacements

```
ggplot(nb_deplacements_w$variables, aes(weight = weights(nb_deplacements_w), x = n)) +  
  geom_density()
```

2.3 Statistiques descriptives

2.3.1 Durée des déplacements

```
temps_moyennes <- svyby(~temps, ~CS8, temps_w, svymean)
```

```
temps_quantiles <- svyby(
  ~temps,
  ~CS8,
  temps_w,
  svyquantile,
  quantiles = c(0.1, 0.25, 0.5, 0.75, 0.9),
  ci = TRUE,
  vartype = "ci"
)
```

```
library(convey)
temps_cw <- convey_prep(temps_w)
temps_gini <- svyby(~temps, ~CS8, temps_cw, svygini)
```

Table 1: Durée quotidienne des déplacements par personne (en min)

PCS (niv. 1)	Moyenne	1er décile	1er quartile	Médiane	3e quartile	9e décile	Coefficient de Gini
[1] Agri.	184.5	0.0	22.3	59.8	175.1	407.2	0.771
[2] Art.	125.1	26.1	60.0	100.0	160.0	225.0	0.426
[3] CPIS	113.2	35.0	69.0	105.0	150.0	195.0	0.322
[4] P.I.	113.5	30.0	60.0	100.0	150.0	203.2	0.350

PCS (niv. 1)	Moyenne	1er décile	1er quartile	Médiane	3e quartile	9e décile	Coefficient de Gini
[5] Empl.	105.9	30.0	55.0	90.0	140.0	195.0	0.361
[6] Ouvr.	119.8	30.0	60.0	100.0	160.0	225.0	0.390
[7] Retr.	87.0	20.0	35.0	70.0	120.0	180.0	0.415
[8] Autres	71.4	17.0	30.0	55.0	95.0	150.0	0.418

2.3.2 Distances parcourues

```
distance_moyennes <- svyby(~distance, ~CS8, distance_w, svymean)
```

```
distance_quantiles <- svyby(
  ~distance,
  ~CS8,
  distance_w,
  svyquantile,
  quantiles = c(0.1, 0.25, 0.5, 0.75, 0.9),
  ci = TRUE,
  vartype= "ci"
)
```

```
library(convey)
distance_cw <- convey_prep(distance_w)
distance_gini <- svyby(~distance, ~CS8, distance_cw, svygini)
```

Table 2: Distances quotidiennes parcourues par personne (en km)

PCS (niv. 1)	Moyenne	1er décile	1er quartile	Médiane	3e quartile	9e décile	Coefficient de Gini
[1] Agri.	26.5	0.0	7.8	27.1	31.3	48.3	0.514
[2] Art.	27.8	0.4	4.5	16.6	40.9	74.3	0.578
[3] CPIS	24.1	2.0	7.8	17.0	33.9	54.0	0.494
[4] P.I.	24.4	1.6	6.7	16.8	33.7	56.4	0.513
[5] Empl.	19.0	0.4	3.6	11.9	27.2	45.1	0.561
[6] Ouvr.	25.2	0.8	5.9	17.2	34.6	59.5	0.536
[7] Retr.	10.9	0.0	0.9	4.2	13.8	29.8	0.664
[8] Autres	9.2	0.4	1.1	3.4	10.8	25.7	0.663

2.3.3 Nombre de déplacements

Calcul de la moyenne

```
nb_deplacements_moyennes <- svyby(~n, ~CS8, nb_deplacements_w, svymean)
```

Calcul des quartiles et quantiles

```
nb_deplacements_quantiles <- svyby(
  ~n,
  ~CS8,
  nb_deplacements_w,
  svyquantile,
  quantiles = c(0.1, 0.25, 0.5, 0.75, .9),
  ci = TRUE,
  vartype= "ci"
)
```

Calcul des coefficients de Gini

```
library(convey)
nb_deplacements_cw <- convey_prep(nb_deplacements_w)
nb_deplacements_gini <- svyby(~n, ~CS8, nb_deplacements_cw, svygini)
```

Table 3: Déplacements quotidiens par personne

PCS (niv. 1)	Moyenne	1er décile	1er quartile	Médiane	3e quartile	9e décile	Coefficient de Gini
[1] Agri.	4.7	2	2.5	4	7	7	0.388
[2] Art.	4.6	2	2.0	4	6	8	0.335
[3] CPIS	4.3	2	2.0	4	6	7	0.298
[4] P.I.	4.3	2	2.0	4	6	8	0.310
[5] Empl.	4.0	2	2.0	4	5	7	0.341
[6] Ouvr.	3.9	2	2.0	4	5	7	0.335
[7] Retr.	3.7	0	2.0	4	5	7	0.375
[8] Autres	3.4	2	2.0	3	4	6	0.288

2.4 Courbes de Lorenz

Attention : pour l'instant, la pondération des données n'est pas prise en compte


2.4.1 Durée des déplacements

```
library(gglorenz)

ggplot(temps_subset_w$variables) +
  stat_lorenz(aes(weight = weights(temps_subset_w), x = temps, colour = "Toutes les PCS"), color = "black") +
  stat_lorenz(aes(weight = weights(temps_subset_w), x = temps, colour = CS8), desc = FALSE) +
  coord_fixed() +
  geom_abline(linetype = "dashed") +
  scale_colour_discrete(name = sjlabelled::get_label(temps_subset_w$CS8)) +
  labs(x = "Part cumulée des individus",
       y = "Part cumulée de la durée des déplacements",
       title = "Inégalités des temps de déplacement")
```

```
## Warning: Ignoring unknown aesthetics: weight
```

```
## Warning: Ignoring unknown aesthetics: weight
```




2.4.2 Distances parcourues

```
library(gglorenz)

ggplot(distance_subset_w$variables) +
  stat_lorenz(aes(weight = weights(distance_subset_w), x = distance, colour = CS8), desc = FALSE) +
  coord_fixed() +
  geom_abline(linetype = "dashed") +
  scale_colour_discrete(name = sjlabelled::get_label(distance_subset$CS8)) +
  labs(x = "Part cumulée des individus",
       y = "Part cumulée des distances parcourues",
       title = "Inégalités des distances parcourues")
```

```
## Warning: Ignoring unknown aesthetics: weight
```




2.4.3 Nombre de déplacements

```
library(gglorenz)

ggplot(nb_deplacements_subset_w$variables) +
  stat_lorenz(aes(weight = weights(nb_deplacements_subset_w), x = n, colour = CS8), desc = FALSE) +
  coord_fixed() +
  geom_abline(linetype = "dashed") +
  scale_colour_discrete(name = sjlabelled::get_label(nb_deplacements_subset_w$CS8)) +
  labs(x = "Part cumulée des individus",
       y = "Part cumulée du nombre de déplacements quotidiens",
       title = "Inégalités du nombre de déplacements quotidiens")
```


```
## Warning: Ignoring unknown aesthetics: weight
```



2.5 Forme des distributions


2.5.1 Durée des déplacements

```
ggplot(temps_subset_w$variables, aes(
  weight = weights(temps_subset_w),
  x = temps / 60,
  color = CS8,
  fill = CS8
)) +
  geom_density(adjust=1.5, alpha = .4) +
  scale_colour_discrete(name = sjlabelled::get_label(temps_subset_w$CS8)) +
  scale_fill_discrete(name = sjlabelled::get_label(temps_subset_w$CS8)) +
  scale_x_continuous(
    breaks = c(seq(0, 4, 1), seq(5, 15, 2)),
    minor_breaks = waiver(),
    sec.axis = dup_axis(name = NULL)
  ) +
  labs(
    title = "Distribution de la durée quotidienne des déplacements, par personne",
    x = "Durée quotidienne des déplacements (en heures)",
    y = "Fréquence"
  )
```




```
ggplot(temps_subset_w$variables, aes(
  weight = weights(temps_subset_w),
  x = temps / 60,
  fill = CS8
)) +
  geom_density(adjust=1.5, position = "fill", alpha = .4) +
  scale_colour_discrete(name = sjlabelled::get_label(temps_subset_w$CS8)) +
  scale_fill_discrete(name = sjlabelled::get_label(temps_subset_w$CS8)) +
  scale_x_continuous(
    breaks = c(seq(0, 4, 1), seq(5, 15, 2)),
    minor_breaks = waiver(),
    sec.axis = dup_axis(name = NULL)
  ) +
  scale_y_continuous(
    breaks = c(0, 0.33, 0.66, 1),
    minor_breaks = waiver(),
    sec.axis = dup_axis(name = NULL)
  ) +
  labs(
    title = "Distribution relative de la durée quotidienne des déplacements, par personne",
    x = "Durée quotidienne des déplacements (en heures)",
    y = "Fréquence relative"
  )
)
```

Distribution relative de la durée quotidienne des déplacements, par person




2.5.2 Distances parcourues

```
ggplot(distance_subset_w$variables, aes(
  weight = weights(distance_subset_w),
  x = distance,
  color = CS8,
  fill = CS8
)) +
  geom_density(adjust=1.5, alpha = .4) +
  scale_colour_discrete(name = sjlabelled::get_label(distance_subset$CS8)) +
  scale_fill_discrete(name = sjlabelled::get_label(distance_subset$CS8)) +
  scale_x_continuous(
    breaks = c(seq(0, 100, 10), 150, 200),
    minor_breaks = waiver(),
    sec.axis = dup_axis(name = NULL)
  ) +
  labs(
    title = "Distribution des distances parcourues quotidiennement par personne",
    x = sjlabelled::get_label(distance_subset$distance),
    y = "Fréquence"
  )
```


```
ggplot(distance_subset_w$variables, aes(
  weight = weights(distance_subset_w),
  x = distance,
  fill = CS8
)) +
  geom_density(adjust=1.5, position = "fill", alpha = .4) +
  scale_colour_discrete(name = sjlabelled::get_label(distance_subset$CS8)) +
  scale_fill_discrete(name = sjlabelled::get_label(distance_subset$CS8)) +
  scale_x_continuous(
    breaks = c(seq(0, 100, 10), 150, 200),
    minor_breaks = waiver(),
    sec.axis = dup_axis(name = NULL)
  ) +
  scale_y_continuous(
    breaks = c(0, 0.33, 0.66, 1),
    minor_breaks = waiver(),
    sec.axis = dup_axis(name = NULL)
  ) +
  labs(
    title = "Distribution relative des distances parcourues quotidiennement par personne",
    x = sjlabelled::get_label(distance_subset$distance),
    y = "Fréquence relative"
  )
)
```

Distribution relative des distances parcourues quotidiennement par person



2.5.3 Nombre de déplacements

```
ggplot(nb_deplacements_subset_w$variables, aes(
  weight = weights(nb_deplacements_subset_w),
  x = n,
  color = CS8,
  fill = CS8
)) +
  geom_density(adjust=1.5, alpha = .4) +
  scale_colour_discrete(name = sjlabelled::get_label(nb_deplacements_subset_w$CS8)) +
  scale_fill_discrete(name = sjlabelled::get_label(nb_deplacements_subset_w$CS8)) +
  scale_x_continuous(
    breaks = seq(0, 22, 2),
    minor_breaks = waiver(),
    sec.axis = dup_axis(name = NULL)
  ) +
  labs(
    title = "Distribution du nombre de déplacements quotidiens par personne",
    x = sjlabelled::get_label(nb_deplacements_subset$n),
    y = "Fréquence"
  )
```



```
ggplot(nb_deplacements_subset_w$variables, aes(
  weight = weights(nb_deplacements_subset_w),
  x = n,
  fill = CS8
)) +
  geom_density(adjust=1.5, position = "fill", alpha = .4) +
  scale_colour_discrete(name = sjlabelled::get_label(nb_deplacements_subset_w$CS8)) +
  scale_fill_discrete(name = sjlabelled::get_label(nb_deplacements_subset_w$CS8)) +
  scale_x_continuous(
    breaks = seq(0, 22, 2),
    minor_breaks = waiver(),
    sec.axis = dup_axis(name = NULL)
  ) +
  scale_y_continuous(
    breaks = c(0, 0.33, 0.66, 1),
    minor_breaks = waiver(),
    sec.axis = dup_axis(name = NULL)
  ) +
  labs(
    title = "Distribution relative du nombre de déplacements quotidiens par personne",
    x = sjlabelled::get_label(nb_deplacements_subset$n),
    y = "Fréquence relative"
  )
)
```

Distribution relative du nombre de déplacements quotidiens par personne

